Laporan Uji Kapasitas Server CoTURN & Signaling Gateway

Video Call WebRTC — pengujian beban bertahap dengan alur panggilan User A → User B yang nyata
Tanggal uji: **Jumat, 13 November 2026 pukul 00.46** · ID run: `2026-11-12-17-46-02` · Target: `34.50.75.236` (WS :3000, TURN UDP :3478) · Uji kapasitas penuh - profil video 574 kbps

1. Ringkasan Eksekutif

KAPASITAS AMAN (MEMENUHI SLA)

250 user

125 video call simultan memenuhi seluruh SLA; diukur dengan generator di server yang sama

TITIK JENUH (BREAKING POINT)

500 user

titik jenuh: SLA mulai dilanggar

SPESIFIKASI SERVER

4 vCPU · 16 GB

e2-standard-4

RATA-RATA DURASI VIDEO CALL

1 mnt 51 dtk

425 panggilan selesai normal · min 1 mnt 36 dtk, maks 2 mnt 13 dtk

PROFIL MEDIA PER USER

574 kbps

per arah (audio Opus + video), lewat relay TURN

Temuan utama

- Pada **500 user** kriteria berikut terlampaui: Packet loss media = **8,18 %** (batas 3); Latensi one-way p95 = **289,2 ms** (batas 150); Waktu setup panggilan p95 = **17.299,48 ms** (batas 3.000).
- Waktu setup panggilan melambat terutama di fase **Koneksi WebSocket** (p95 **8.581 ms**), yang ditangani oleh **signaling gateway**. Saat ramp-up tahap ini CPU server memuncak **100%** dan CPU gateway **89,9%** dari satu core, sedangkan setelah semua panggilan tersambung kualitas media tetap baik (loss 8,18%).
- Beban gateway bersifat **lonjakan saat banyak user masuk/memanggil**: setiap register/call/accept/hangup memicu pengiriman daftar seluruh user ke semua client, sehingga antrean pesan signaling (offer/answer/ICE) tertahan di belakang broadcast tersebut. Saat panggilan sudah berjalan, CPU gateway kembali rendah (0,6%).
- Selama tahap 500 user, gateway mengirim **4.942,4 MB** pesan daftar user (`type:"users"`) dalam 253.182 pesan. Lalu lintas ini tumbuh kuadratik terhadap jumlah user.
- Porsi CPU untuk **softirq (pemrosesan paket jaringan di kernel)** mencapai 18,6%; beban paket UDP (pps) menjadi faktor dominan.
- Kernel membuang datagram UDP karena buffer socket penuh (**14.689 /detik** RcvbufErrors pada puncak) — karena generator berjalan di server yang sama dan sedang jenuh, sebagian besar drop ini kemungkinan terjadi di socket *generator* yang tidak sempat dibaca, bukan hanya di CoTURN.
- Load generator dijalankan **di server yang sama**. CPU yang dipakai generator dicatat terpisah dan **dikeluarkan** dari penilaian SLA CPU (kolom “CPU tanpa generator”); kebutuhan CPU CoTURN dan gateway diukur per proses sehingga tidak tercampur.
- **Estimasi kapasitas bila server hanya menjalankan CoTURN + gateway** (tanpa generator): dari regresi CPU tanpa generator (≈0,136% CPU per user), batas 85% CPU tercapai pada sekitar **610 user**. Ini ekstrapolasi; untuk membuktikannya jalankan generator dari mesin terpisah.

Rekomendasi

- Hentikan `broadcastUserList()` ke *semua* client pada setiap register/call/accept/hangup (biaya $O(N^2)$); kirim hanya perubahan (delta) atau hanya ke pihak terkait.
- Ganti `fs.appendFileSync` di setiap log dengan logger asinkron (mis. stream/pino) atau matikan log per-pesan di produksi.
- Jalankan gateway dalam mode cluster PM2 (mis. 4 instance) dengan sticky session atau broker (Redis pub/sub) agar memakai semua core.
- Aktifkan multi-queue NIC / RPS, dan naikkan `net.core.netdev_max_backlog`.
- rmem_max server sudah 25 MB; naikkan juga `net.core.rmem_default` karena socket yang tidak meminta ukuran buffer khusus memakai nilai default ini, dan pertimbangkan `relay-threads` sama dengan jumlah vCPU di CoTURN.
- CoTURN berjalan dengan opsi `verbose` dan menulis log ke file; di produksi matikan `verbose` agar CPU dan disk tidak terbebani log per-paket/per-alokasi.
- Untuk angka kapasitas murni CoTURN, ulangi uji dengan load generator di VM terpisah dalam region yang sama (opsi `--monitor ssh`).

2. Skenario Stress Test Virtual User (VU)

Apa itu Virtual User (VU)?

Satu **VU** adalah satu pengguna aplikasi yang disimulasikan secara penuh oleh program uji, bukan sekadar request HTTP. Setiap VU memiliki:

- koneksi **WebSocket** sendiri ke signaling gateway (seperti browser yang membuka aplikasi),
- **socket UDP** dan **alokasi relay TURN** sendiri di CoTURN (seperti ICE agent WebRTC),
- aliran media **dua arah** ±574 kbps per arah (audio Opus + video) yang benar-benar diteruskan oleh CoTURN.

VU selalu berpasangan: **User A (dokter, APP_A)** yang menekan tombol panggil dan **User B (pasien, APP_B)** yang menerima. Jadi *N* VU = *N*/2 video call yang berlangsung **bersamaan**.

Siklus hidup satu pasangan VU

1. **Masuk aplikasi** — A & B connect WebSocket + `register`.
2. **Panggil** — A `call` → B `incoming` → B `accept`.
3. **Siapkan jalur media** — A & B TURN Allocate, tukar `offer/answer` + kandidat `relay`, CreatePermission + ChannelBind.
4. **Bicara** — media video/audio mengalir dua arah lewat CoTURN selama sisa ramp-up + seluruh jendela pengukuran.
5. **Tutup** — A `hangup`, kedua VU melepas relay (Refresh lifetime 0) dan menutup koneksi.

Pola beban: step-load (tangga) sampai titik jenuh

- **Bertahap**: rencana 100 → 250 → 500 → 750 → 1.000 → 1.500 → 2.000 → 2.500 → 3.000 → 4.000 → 5.000 VU; dijalankan sampai **500 VU**. Tiap tahap dimulai dari nol agar hasil antar tahap tidak saling memengaruhi.
- **Ramp-up**: panggilan dimulai merata sepanjang durasi ramp (kolom *laju kedatangan* = VU baru per detik), meniru pengguna yang masuk tidak serentak.
- **Tahan (hold)**: setelah semua panggilan tersambung, beban ditahan 90 detik. Semua metrik kualitas dan sumber daya server di laporan ini diambil dari jendela ini (kondisi stabil/*steady-state*).
- **Hangup & cooldown** 30 detik, menunggu CoTURN melepas semua port relay sebelum tahap berikutnya.
- **Berhenti otomatis** pada tahap pertama yang melanggar SLA (breaking point) — kapasitas aman = tahap terakhir sebelum itu.
- VU dijalankan oleh beberapa proses *worker* paralel di **server yang sama** (CPU generator dipisahkan dari penilaian); total durasi pengujian 7 menit.

Profil beban: Virtual User (VU) aktif selama pengujian (VU dalam panggilan aktif)

tangga naik per tahap: ramp-up → tahan (pengukuran) → hangup → cooldown



Jadwal & realisasi beban per tahap

Tahap	Target VU	Video call bersamaan	Durasi ramp-up	Laju kedatangan (VU/dtk)	Durasi tahan	Puncak VU aktif	Durasi call rata-rata	Lama tahap	Worker	Hasil
1	**100**	50	10 dtk	10	90 dtk	100	1 mnt 41 dtk	106 dtk	1	✓ LULUS
2	**250**	125	10 dtk	25	90 dtk	250	1 mnt 42 dtk	107 dtk	2	✓ LULUS
3	**500**	250	20 dtk	25	90 dtk	500	1 mnt 58 dtk	134 dtk	3	✕ GAGAL generator jenuh

3. Hasil Pengujian per Tahap

Status: ✓ LULUS semua kriteria SLA terpenuhi · ▲ WASPADA ada metrik melewati batas waspada · ✕ GAGAL minimal satu kriteria SLA dilanggar. Nilai server adalah rata-rata/puncak selama **jendela pengukuran 90 detik** saat semua panggilan aktif (fase steady-state).

3a. Kualitas Layanan Panggilan

User	Panggilan tersambung	Sukses	Setup p50 / p95 (ms)	Call→Accept p95 (ms)	TURN Allocate p50 / p95 (ms)	Packet loss	Jitter p95 (ms)	Latensi one-way p50 / p95 (ms)	Durasi call rata-rata (dtk)	Putus saat aktif	Status
100	50 / 50	100%	46 / 65	17	3 / 8	0%	0,9	6 / 10	101	0	✓ LULUS
250	125 / 125	100%	65 / 472	79	6 / 55	0%	1	8 / 13	102	0	✓ LULUS
500	250 / 250	100%	541 / 17.299	5.106	44 / 574	8,18%	10,6	153 / 289	118	0	✕ GAGAL generator jenuh

3b. Sumber Daya Server

User	CPU total avg / max	CPU tanpa generator (avg)	CPU generator (% 1 core)	Core tersibuk	Load avg (1m)	CPU CoTURN (% 1 core)	CPU Gateway avg / max (% 1 core)	RAM terpakai	RAM CoTURN	RAM Gateway	softirq / steal	Status
100	26,6% / 30,8%	**15,5%**	44,3%	42,6%	0,75	54,6%	0,3% / 2%	806 MB (5%)	43 MB	83 MB	5,7% / 0,2%	✓ LULUS
250	64,4% / 72,5%	**35,9%**	114,1%	76,3%	2,81	131%	0,4% / 1%	877 MB (5,5%)	43 MB	90 MB	13% / 0,4%	✓ LULUS
500	99,8% / 100%	**48,7%**	204,6%	100%	6,64	186,1%	0,6% / 4%	2.234 MB (14%)	43 MB	1.124 MB	18,6% / 1,2%	✕ GAGAL generator jenuh

3c. Jaringan & Sumber Daya Socket

User	Bandwidth masuk / keluar (Mbps)	Paket/detik masuk / keluar	UDP drop kernel: buffer penuh / total error (/s)	NIC drop (/s)	Port relay aktif	File descriptor CoTURN	Koneksi TCP (WS)	Broadcast daftar user	Retransmisi TURN
100	124,8 / 124,8	30.006 / 30.006	0 / 0	0	100	149	118	39,1 MB	0
250	312 / 312	75.003 / 75.003	0 / 0	0	250	299	268	602,9 MB	0
500	488,3 / 488,3	117.364 / 117.364	14.689 / 14.689	0	500	549	517	4.942,4 MB	0

3d. Durasi Video Call

Durasi bicara = sejak media dua arah mulai mengalir sampai hangup. Durasi sesi = sejak User A menekan panggil sampai hangup. Panggilan yang dimulai di awal ramp-up berlangsung lebih lama daripada yang dimulai di akhir.

User	Panggilan selesai normal	Durasi bicara rata-rata	Median	Terpendek	Terlama	Durasi sesi rata-rata
100	50	**1 mnt 41 dtk**	1 mnt 40 dtk	1 mnt 36 dtk	1 mnt 45 dtk	1 mnt 41 dtk
250	125	**1 mnt 42 dtk**	1 mnt 42 dtk	1 mnt 36 dtk	1 mnt 47 dtk	1 mnt 42 dtk
500	250	**1 mnt 58 dtk**	2 mnt 02 dtk	1 mnt 36 dtk	2 mnt 13 dtk	2 mnt 01 dtk

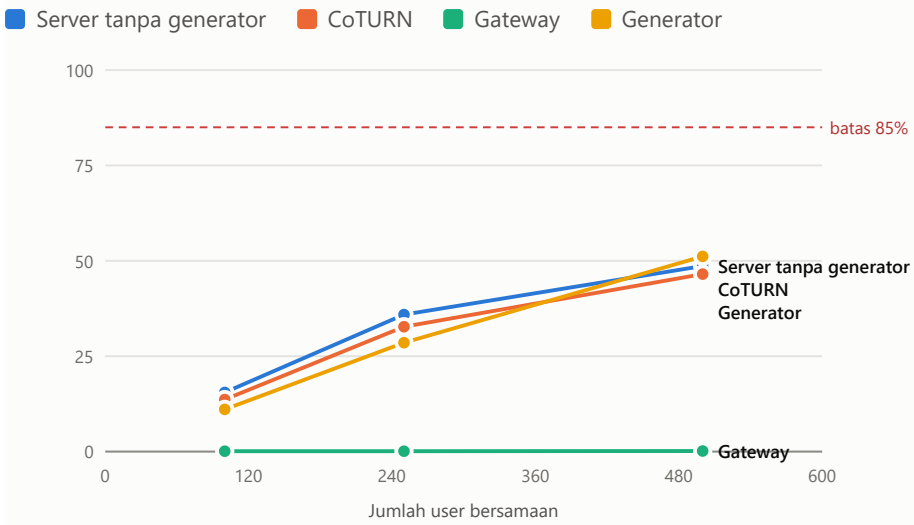
3e. Rincian Waktu Setup Panggilan per Fase (p95, ms)

Menunjukkan komponen mana (signaling gateway atau CoTURN) yang memperlambat proses tersambungnya panggilan ketika jumlah user naik.

User	Koneksi WebSocket signaling gateway	Register user signaling gateway	Call → Incoming → Accept signaling gateway	TURN Allocate CoTURN	Offer/Answer + ICE candidate signaling gateway	CreatePermission + ChannelBind CoTURN	Total setup p95
100	10	11	17	8	10	6	**65**
250	57	47	79	55	105	51	**472**
500	8.581	951	5.106	574	6.834	496	**17.299**

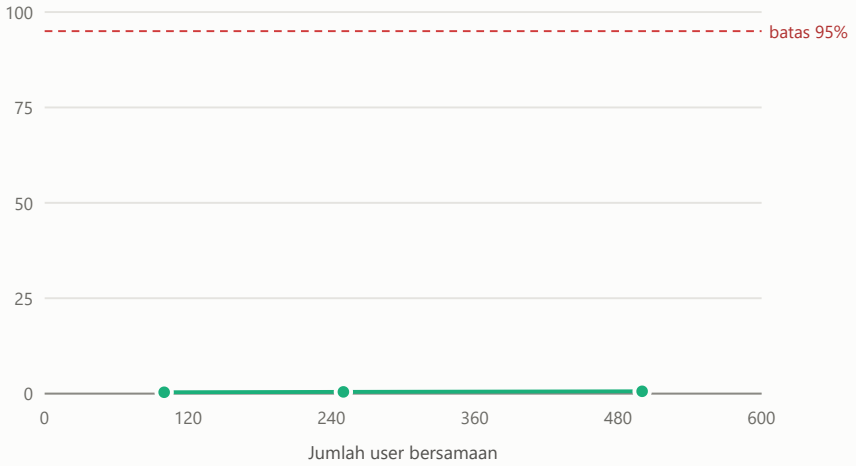
4. Grafik Tren terhadap Jumlah User

CPU terpakai (% kapasitas seluruh server)



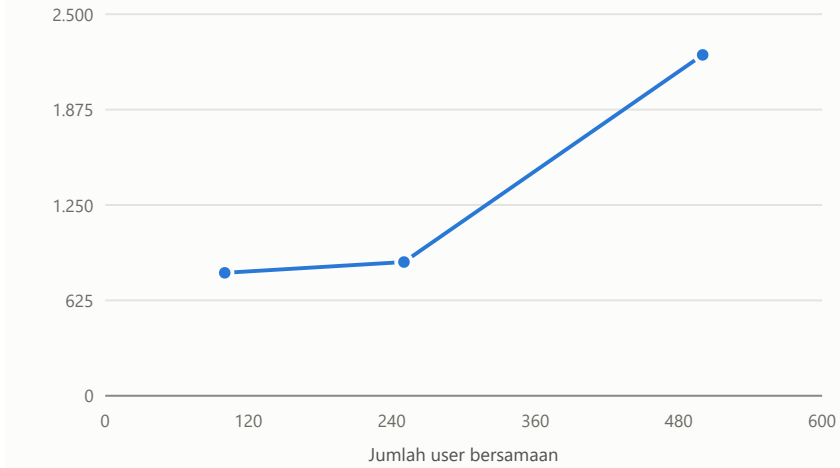
CPU gateway Node.js (% dari 1 core)

Node.js satu thread: 100% = jenuh

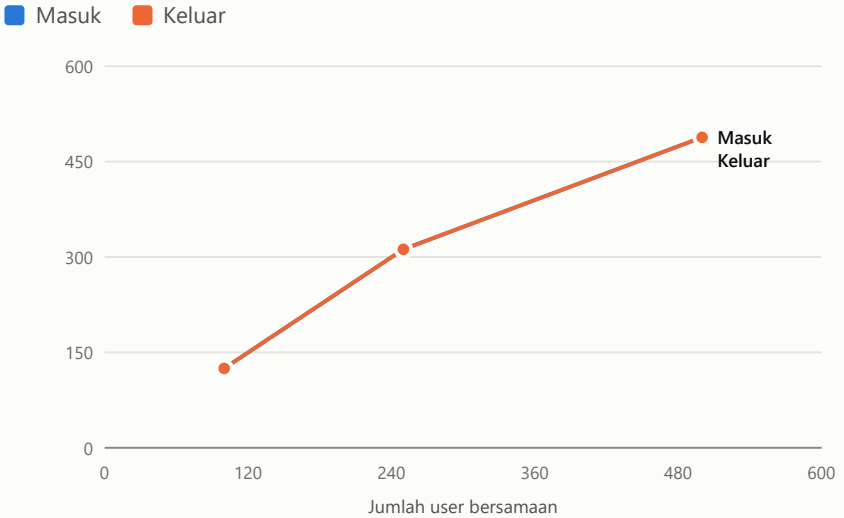


RAM terpakai (MB)

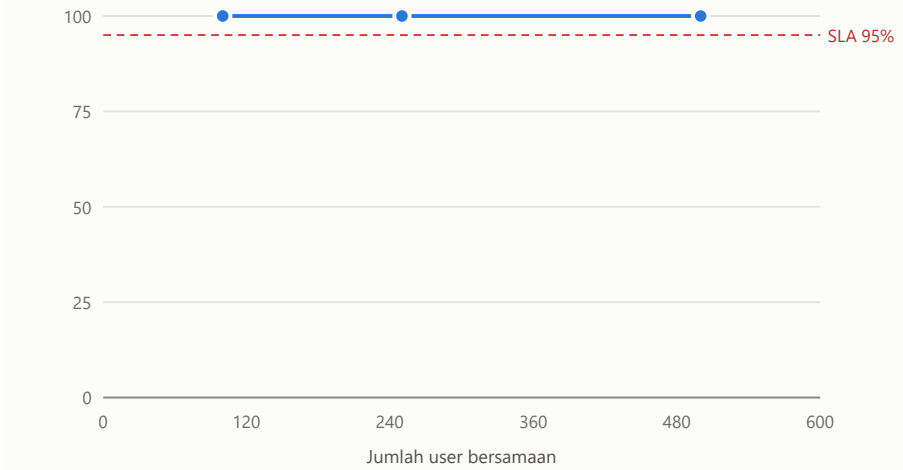
Total RAM 15.997 MB



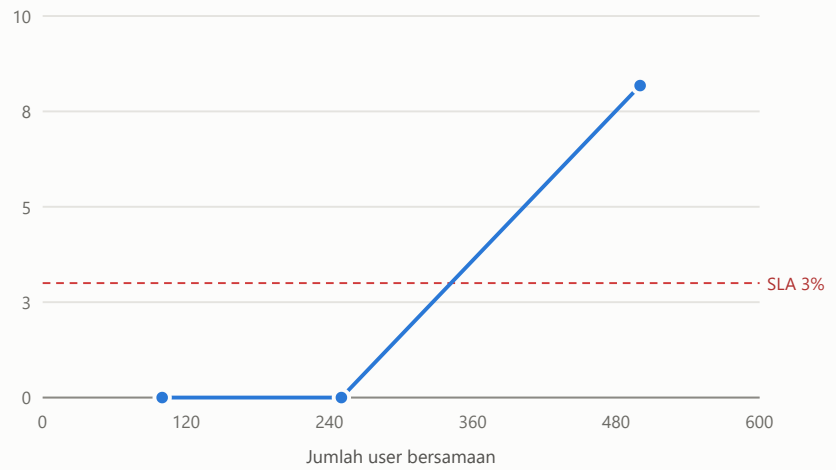
Throughput jaringan server (Mbps)



Panggilan berhasil tersambung (%)

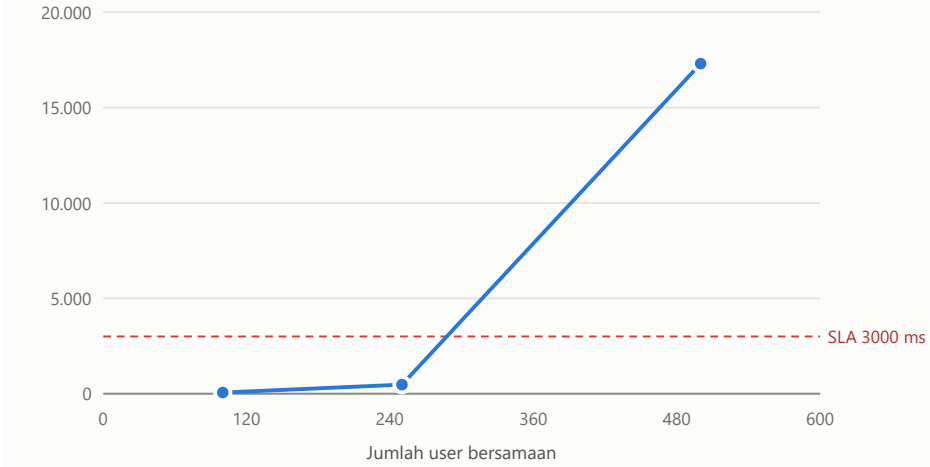


Packet loss media (%)

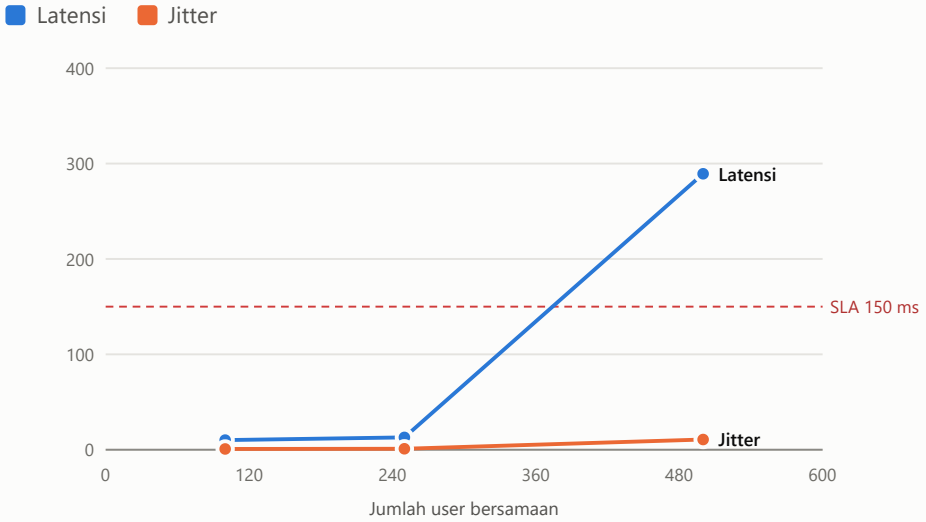


Waktu setup panggilan p95 (ms)

register → media dua arah mengalir

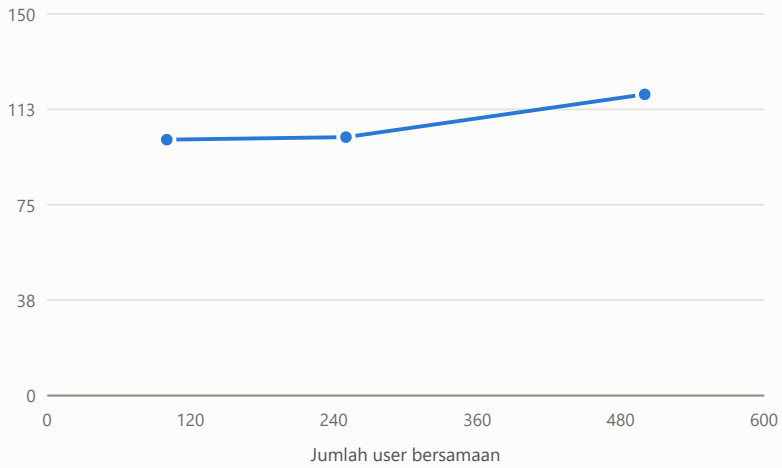


Latensi media one-way & jitter (ms, p95)



Durasi video call rata-rata (detik)

media mengalir → hangup



5. Lingkungan Pengujian

Server yang diuji

Host	temp-stress-test (asia-southeast2-b)
Tipe mesin	e2-standard-4
CPU	4 vCPU — Intel(R) Xeon(R) CPU @ 2.20GHz
RAM	15.997 MB
OS / kernel	Debian GNU/Linux 13 (trixie) / 6.12.116+deb13-cloud-amd64
Interface	ens4
CoTURN	coturn 4.6.1-2
Rentang port relay	10000–65535 (55.536 port)
Sysctl rmem_max / backlog	26.214.400 B / 1.000
Kondisi idle (sebelum uji)	CPU 0,5%, RAM 780 MB

Konfigurasi CoTURN (turnserver.conf)

`listening-port`	3478
`listening-ip`	0.0.0.0
`external-ip`	34.50.75.236/10.184.0.23
`min-port`	10000
`max-port`	65535
`realm`	34.50.75.236
`lt-cred-mech`	aktif
`fingerprint`	aktif
`verbose`	aktif
`log-file`	/var/log/turnserver.log

Mesin load generator

Lokasi	Server yang sama (34.50.75.236, e2-standard-4)
Host	temp-stress-test — Linux 6.12.116+deb13-cloud-amd64
CPU / RAM	4 core Intel(R) Xeon(R) CPU @ 2.20GHz / 15.997 MB
Node.js	v20.20.2

6. Metodologi & Kriteria

Skenario per pasangan panggilan

Setiap tahap membuat *N*/2 pasangan. User A (aplikasi dokter) memanggil User B (aplikasi pasien) dengan protokol yang sama seperti aplikasi asli:

1. A dan B membuka WebSocket ke gateway lalu mengirim `register`.

Profil beban & tahapan

- Profil media: paket setiap 20 ms — audio 172 B + video 625 B + video 625 B ≈ **574 kbps** dan 150 paket/detik per arah per user.

2. A mengirim `call` (mode video), B menerima `incoming` lalu mengirim `accept`.
3. A dan B masing-masing melakukan **TURN Allocate** ke CoTURN (tantangan 401 → kredensial long-term, RFC 5766).
4. Pertukaran SDP `offer` / `answer` dan ICE `candidate` bertipe `relay` lewat gateway.
5. A dan B melakukan **CreatePermission** + **ChannelBind** ke alamat relay lawan.
6. Media dua arah mengalir sebagai **ChannelData**: A → CoTURN → relay A → relay B → CoTURN → B (dan sebaliknya).
7. Setelah jendela pengukuran: A mengirim `hangup`, keduanya melepas alokasi (Refresh lifetime 0).

Panggilan dihitung **berhasil** hanya jika media benar-benar diterima di kedua arah melalui relay CoTURN.

- Tahapan: 100 → 250 → 500 user (rencana: 100, 250, 500, 750, 1000, 1500, 2000, 2500, 3000, 4000, 5000).
- Setiap tahap: *ramp-up* bertahap (panggilan dimulai merata), lalu **90 detik jendela pengukuran** dengan semua panggilan aktif, kemudian teardown dan cooldown 30 detik sampai port relay CoTURN kembali dilepas.
- Pengujian otomatis berhenti pada tahap pertama yang melanggar SLA (breaking point).
- Telemetri server dicatat setiap 1 detik oleh agen di server (/proc): CPU per core & per proses, RAM, jaringan, statistik UDP kernel, port relay, file descriptor.
- Latensi one-way dan jitter diukur dari timestamp di setiap paket; pengirim dan penerima berada di proses yang sama sehingga jamnya identik.

Kriteria SLA

Metrik	Lulus	Gagal bila
Panggilan berhasil (media 2 arah)	≥ 99%	< 95%
Packet loss media	≤ 1%	> 3%
Jitter p95 (RFC 3550)	≤ 20 ms	> 30 ms
Latensi one-way p95 (ITU-T G.114)	≤ 100 ms	> 150 ms
Waktu setup panggilan p95	≤ 1500 ms	> 3000 ms
CPU server rata-rata	≤ 70%	> 85%
RAM server	≤ 80%	> 90%
CPU gateway Node.js (1 core)	≤ 70%	> 95%

7. Lampiran

Biaya sumber daya per user

CPU server per user	≈ 0,136%
RAM per user	≈ 0,42 MB
Bandwidth keluar per user	≈ 1,248 Mbps
Estimasi user saat CPU 85% (ekstrapolasi linear)	≈ 610

Dihitung dengan regresi linear dari tahap-tahap yang memenuhi SLA. Ekstrapolasi hanya perkiraan; pembatas non-CPU (gateway, jaringan) bisa muncul lebih dulu.

Rincian penyebab kegagalan panggilan

User	Fase: penyebab ×jumlah
Tidak ada kegagalan panggilan.	

Kesehatan load generator (validitas data)

Jika event-loop generator > 100 ms atau CPU-nya > 90%, angka di tahap tersebut bisa dibatasi oleh generator, bukan oleh server.

User	Worker	Event loop p99	CPU worker maks	Media dikirim	Kondisi
100	1	17,5 ms	44,1%	56,9 Mbps	normal
250	2	23,1 ms	57,4%	142,2 Mbps	normal
500	3	218,2 ms	68,9%	232 Mbps	⚠ jenuh